

Avance — Samu Enjoyers

Punto de control — Hackathon 2026

2 de octubre de 2026

Santiago Gómez, Camilo Murcia, Angie Gutiérrez

1. Corpus y descarga

31.157 documentos objetivo; **31.037 descargados y convertidos a Markdown** (99,6 %; 117 fallas y 3 duplicados documentados en la auditoría), 24,9 GB de originales, con OCR (Tesseract) donde la capa de texto era ilegible. Fuentes: Senado, SUIN-Juriscol, relatorías de la Corte Constitucional, la Corte Suprema y el Consejo de Estado, DAPRE, DIAN y SIC. Las 10 áreas del banco tienen cobertura de su código o ley principal y de jurisprudencia. Segmentación: un chunk por artículo con ruta jerárquica y encabezado citable (artículos largos en partes) y sentencias en ficha (tesis y resuelve) más ventanas de unos 1.700 caracteres; **2.210.629 chunks** indexados con metadatos de vigencia.

2. Recuperación híbrida (congelada)

BM25 (bm25s, raíces Snowball) + FAISS HNSW SQ8 con **Qwen3-Embedding-0.6B** + lista extra solo de normas (para que las sentencias, 85 % del corpus, no entierren códigos) → fusión RRF ($k=60$) → **bge-reranker-v2-m3** sobre 150 candidatos → 10 pasajes. Ajustes: castigo por tipo y por norma derogada, tope de pasajes por documento, filtro de casi duplicados (≥ 70 %), salario mínimo para montos en pesos y expansión de siglas. Sobre **sample_50**: **recall_citas@10 0,931, recall_docs@10 0,858** (sin ajustes: 0,862 / 0,439; opción múltiple 0,962 / 0,808). El resultado es determinista y coincide pasaje a pasaje entre la A40 y el portátil (50/50); ~1 s por pregunta.

3. Agente y grounding

LegalAgent sobre un grafo LangGraph (entrada → consulta/reescritura → recuperación → escritura → validación de fuentes → salida), sin memoria entre preguntas. Escritor **Qwen3-8B GGUF Q4_K_M** (llama.cpp), $T=0$, **top_k=1**, semilla fija, sin modo de razonamiento, JSON guiado y redacción *exclusivamente* con los 10 pasajes. Las flags de formato/área/complejidad/sub-tarea deciden el buscador y el estilo de respuesta. **Validación determinista (sin LLM)**: cada cita se mapea a un ID canónico **doc_id/art_N** y se suprime si no está en los 10 pasajes; sin citas respaldadas o sin respuesta del LLM, el agente se abstiene (**abstencion: true**); las cerradas siempre entregan letra. Con **cache_prompt: false** dos corridas dan respuestas idénticas (reproducibles para la verificación en vivo). Solo modelos abiertos y locales.

4. Pruebas y resultados en sample_50

Componente (evaluador oficial, sin RAGAS)	Puntos	Posibles	Detalle
Exactitud en cerradas	17,33	20	13/15 (0,867; ref. 0,905)
Calidad de citación	18,37	20	0 citas sin respaldo
Abstención calibrada	9,07	10	
Total automático	44,77	50	
RAGAS (juez oficial, 35 ítems)	~14,1	30	0,470 (ref. 0,451)
Total estimado	~58,9	80	

Latencia en la A40: **8,9 s por pregunta** (cerradas 10,8; semiabiertas 7,5; abiertas 12,3), unos 7 min para las 50. Hoy se probaron y **descartaron con datos** (RAGAS contra 0,470): largo según complejidad (0,447), ejemplos de estilo (0,468), oraciones sustantivas (0,457) y modo de razonamiento (0,441, con el doble de tiempo); el juez Gemma salió también de la entrega (sin juez: 13/15 y RAGAS 0,485 contra 12/15 y 0,469, y la mitad del tiempo). Incluidas: siglas y fuentes ampliadas (+1,9 pts de citación y abstención). Una auditoría de sobreajuste (remuestreo y ablaciones) no halló reglas atadas a preguntas concretas. Las cerradas 128 y 748 no tienen respaldo alcanzable en el corpus.

5. Riesgos y próximos pasos (sábado)

- Verificación en vivo:** correr 3 preguntas dos veces en la RTX 4090 (24 GB) y comprobar respuestas idénticas a las de la corrida de las 992; un solo proceso, sin **-np > 1**. Mismo GGUF y banderas en ambas.
- Tiempo:** las 992 preguntas, estimadas en ~1,7–2 h (~6–7 s cada una) en **tmux**; margen amplio frente al límite de 5 h.
- Pruebas a ciegas:** confirmar métricas y tiempos con **evaluate.py** en la 4090 y revisar que no haya **null** en cerradas ni citas fuera de los pasajes; el juez LLM queda apagado (opcional con **-juez**).
- Entregables restantes:** enlace público del zip del índice (4,59 GB) en README, CORPUS.md y manifiesto; interfaz gráfica, video y limpieza de resultados de prueba del repositorio.
- Techo de contenido:** el puntaje queda limitado por lo que la búsqueda no trae (60, 247, 679) y por el razonamiento del 8B en preguntas de borde.