

Informe técnico — Samu-Enjoyer

RAG agéntico de derecho colombiano con modelos abiertos pequeños

Santiago Gómez Camilo Murcia Angie Gutiérrez

Hackathon 2026 · Universidad de los Andes

1. Arquitectura del sistema

El sistema responde preguntas de derecho colombiano con un decoder abierto de 8B de parámetros y un corpus propio, bajo una regla: *toda norma citada debe figurar en los diez pasajes recuperados*. Tiene una parte fuera de línea y una en línea.

Fuera de línea (corpus e índice). Se descargaron 31.157 documentos objetivo de fuentes oficiales (Senado, Presidencia, relatorías de la Corte Constitucional, la Corte Suprema y el Consejo de Estado, DIAN, Función Pública, Cancillería y Colpensiones): **31.037 quedaron procesados (99,6 %)**, 24,86 GB de originales; las 117 fallas son documentos que la fuente oficial ya no entrega. Cada documento se convirtió a Markdown con metadatos (`tipo_norma`, `numero`, `anio`, `vigencia`); las capas de texto ilegibles se relevaron con OCR. La segmentación produjo 2.210.629 chunks: 276.958 de normas (un artículo por chunk), 23.954 fichas de sentencias y 1.909.717 ventanas de sentencias. El 3 de octubre, con autorización de los organizadores, se agregaron 9 fuentes oficiales que cita el test y no estaban (Resolución 368 de 2014, Ley 99 de 1993, Decreto 4302 de 2008, tres sentencias T y tres del Consejo de Estado): 730 chunks agregados al final de los índices sin recalcular lo existente, para un total de **2.211.359 chunks**.

En línea. El flujo es un `StateGraph` de `LangGraph`, sin memoria entre preguntas y sin ramas paralelas: `entrada` → `consulta_cerrada` | `reescribir_consulta` → `recuperar` → `escribir` → `validar_fuentes` ↔ `buscar_citas` → `finalizar`. La consulta no pasa por el LLM: las cerradas buscan con la pregunta más sus cuatro opciones y el texto libre con la pregunta tal cual, con las siglas jurídicas expandidas por un diccionario fijo (“SIC” → “Superintendencia de Industria y Comercio”). El escritor redacta solo con los diez pasajes, un validador determinista revisa las citas y un post-proceso determinista ajusta la salida al esquema oficial. Un ciclo por pregunta: el juez y su segundo ciclo existen en el código, pero la entrega no los usa (sección 4). Ninguna llamada sale de la máquina: los modelos se sirven en `localhost`. La interfaz gráfica (React y una API local con FastAPI) usa el mismo agente, así que muestra lo mismo que se entrega.

2. Selección de encoder y decoder

La elección se hizo con un banco de pruebas sobre las 50 preguntas de muestra: 3 encoders × BM25 con y sin

raíces × 2 rerankers y sin reranker, en el subcorpus de normas y fichas (300.912 chunks). La Tabla 1 resume los brazos comparables y la Tabla 2, la decisión.

Tabla 1: Banco de pruebas, subcorpus de normas y fichas, $k = 10$, $n = 50$. R-c: recall de citas; R-d: recall de documentos; s: segundos del reranker por pregunta (servidor de referencia).

Brazo	R-c	R-d	MRR	nDCG	s
<i>Encoder (BM25 con raíces + bge-reranker-v2-m3, sin ajustes)</i>					
Qwen3-Embedding-0.6B	0,898	0,715	0,431	0,554	0,25
e5-large-instruct	0,911	0,667	0,390	0,509	0,26
bge-m3	0,874	0,679	0,405	0,522	0,26
<i>Reranker (Qwen3-Embedding-0.6B + BM25 con raíces)</i>					
bge-reranker-v2-m3	0,898	0,715	0,431	0,554	0,25
Qwen3-Reranker-0.6B	0,833	0,654	0,337	0,461	1,14
Sin reranker	0,841	0,707	0,436	0,572	—
<i>Con ajustes de orden (perfil completo)</i>					
Qwen3-Emb. + bge-rer.	0,935	0,837	0,448	0,601	0,25
e5-large + bge-rer.	0,898	0,752	0,399	0,537	0,26

Sin ajustes, e5-large-instruct recupera algo más de citas (0,911 contra 0,898), pero Qwen3-Embedding-0.6B trae más documentos de referencia y los ordena mejor, y con los ajustes de orden gana en las cuatro métricas. Qwen3-Reranker-0.6B empeora todas las métricas frente a no reordenar y es 4,5 veces más lento (1,14 s contra 0,25 s).

Configuración de inferencia. Cuantización de 4 bits (Q4_K_M), contexto de 32.768 tokens, temperatura 0, `top_k = 1`, semilla 42, sin modo de razonamiento, una petición a la vez (`-np 1`) y sin caché de prompts (`cache_prompt: false`): con la caché, la salida dependía de la pregunta anterior y dos corridas daban 0 de 50 respuestas idénticas; sin ella, dos corridas son idénticas. Los diez pasajes comparten un presupuesto de 85.000 caracteres: los que caben van completos y solo se recortan los gigantes; si aun así el prompt excede el contexto, se reintenta una vez con el presupuesto reducido en proporción (1 de 992 preguntas). Las 992 preguntas del test corrieron en una RTX 4090 de 24 GB en 1,1 h, **4,0 s por pregunta** en promedio, en la misma máquina de la verificación en vivo.

3. Estrategia de recuperación

Segmentación. Un chunk por artículo, con su ruta jerárquica y un encabezado citable; los artículos largos se parten y se reúnen al entregar. Notas, preámbulos y anexos van aparte. Cada sentencia aporta una ficha (tesis y resuelve) y ventanas de ≈ 1.700 caracteres por sección. El identificador canónico es `<doc_id>/art_<N>`, por ejemplo

Tabla 2: Componentes elegidos.

Componente	Modelo	Motivo de la elección	Alternativas descartadas
Encoder	Qwen/Qwen3-Embedding-0.6B (dim. 1024), FAISS HNSW con cuantización escalar de 8 bits	Mejor recall de documentos y mejor orden del banco; 0,935 / 0,837 con ajustes. Cabe en un portátil de 4 GB (corre en CPU) con los mismos pasajes que en el servidor de referencia.	bge-m3 (0,874 / 0,679) y e5-large-instruct (0,911 / 0,667)
Decoder	Qwen/Qwen3-8B, GGUF Q4_K_M en llama.cpp	Abierto, dentro del límite de 8B; el mismo motor y el mismo archivo corren en el servidor de referencia y en el portátil de la verificación en vivo.	Modo de razonamiento de Qwen3: RAGAS 0,441 contra 0,470 sin razonamiento (misma fecha) y el doble de tiempo
Reranker	BAAI/bge-reranker-v2-m3 (fp16) sobre 150 candidatos	Sube el recall de citas de 0,841 a 0,898 en el banco; 0,66 s por pregunta en el corpus completo.	Qwen3-Reranker-0.6B: peor (0,833 / 0,654) y 4,5× más lento
Juez	Gemma 4 E4B en Ollama, apagado en la entrega	Medido y descartado: sin juez, RAGAS 0,485 contra 0,469, cerradas 13/15 contra 12/15 y la mitad del tiempo (sección 4).	Qwen3-8B como juez de sus propios borradores (llama.cpp ignora el campo model)

codigo_general_proceso/art_42.

Búsqueda híbrida. Cinco listas entran a una fusión RRF ($k = 60$): las citas expresas de la pregunta (búsqueda exacta por identificador), BM25 (bm25s, raíces Snowball, sin quitar *stopwords*, identificadores normativos en un solo token; 100 candidatos; solo en cerradas, porque en lenguaje natural trae pasajes que comparten palabras pero no tema), HNSW denso ($M = 32$, efSearch = 256; 100 candidatos) y una *lista de normas*: BM25 y HNSW sobre solo los 276.958 chunks de normas, 50 candidatos cada uno. Esta lista existe porque las sentencias son el 86 % del corpus y dejaban los códigos y la Constitución en las posiciones 100 a 900. Si la pregunta trae un monto en pesos, entra el decreto vigente del salario mínimo (los umbrales legales están en SMLMV); en las cerradas, el primero de BM25 de normas tiene lugar asegurado.

Reordenamiento y selección. El reranker puntúa los 150 primeros de la fusión. Después se castiga por tipo (preámbulo 0,2; notas 0,15; ventana de sentencia 0,1; anexo 0,1) y por vigencia (**norma derogada 0,15**), se suma 0,1 a las normas de prioridad alta, y se limita a 4 sentencias y 3 pasajes por documento. Un filtro de casi duplicados salta el pasaje que no es artículo de norma y repite al menos el 70 % del texto de uno ya elegido (65 de 500 pasajes de la muestra repetían a otro). Salen **10 pasajes**; todo empate se resuelve por identificador, así que el resultado es determinista: el portátil (RTX 3050 Ti / CPU) devolvió los mismos 10 pasajes en el mismo orden que el servidor de referencia en 50 de 50 preguntas.

Tabla 3: Corpus completo (2.210.629 chunks), $k = 10$, $n = 50$.

Configuración	R-c	R-d	MRR	nDCG
Sin ajustes (base)	0,862	0,439	0,236	0,314
+ castigos, prioridad y topes	0,862	0,667	0,294	0,421
+ 150 al reranker, castigo ventanas	0,898	0,764	0,380	0,520
+ lista de normas (50 + 50)	0,919	0,785	0,416	0,552
+ sin casi duplicados	0,919	0,809	0,419	0,561
+ BM25 solo cerradas (final)	0,931	0,858	0,423	0,577

Por formato, configuración final (R-c / R-d)

Cerradas (15): 0,962 / 0,808

Semiabiertas (30): 0,986 / 0,944

Abiertas (5): 0,500 / 0,500

La Tabla 3 muestra el recorrido. El recall de documen-

tos casi se duplica (0,439 a 0,858): es el techo de citas del agente, porque el validador solo acepta citas de documentos presentes en los diez pasajes. Se probaron y descartaron, con datos: una búsqueda por cada opción en las cerradas (recall de documentos 0,772), el seguimiento de las normas citadas por los primeros resultados (sin cambio), más candidatos sin más reranker, y topes más estrictos de sentencias.

4. Verificación de citas y abstención

El escritor cita con identificadores canónicos entre corchetes. La verificación es **determinista y sin LLM**: cada cita se convierte a <doc_id>/art_<N> y se busca entre los diez pasajes; la que no está se suprime del borrador (nodo **buscar_citas**). Agregar el pasaje de una cita ausente está implementado y apagado: la afirmación no se habría redactado con ese texto y los pasajes dejarían de depender solo de la búsqueda que se reproduce en la verificación en vivo.

Al entregar, cada identificador se reescribe a la forma que reconoce el evaluador oficial con el nombre que trae el encabezado del pasaje (“artículo 42 del Código General del Proceso (Ley 1564 de 2012)”). Con los pasajes reales de las 50 preguntas, **401 de 410 citas quedan reconocidas y respaldadas**; las 9 restantes son sentencias de la Corte Suprema sin cita reconocible en su propio texto.

Además, se agregan al fundamento las normas y sentencias de los pasajes consultados y las leyes y códigos que esos pasajes mencionan: quedan respaldadas y salen de la búsqueda determinista. La citación subió de 16,73 a 18,37 puntos sin ninguna cita sin respaldo.

Abstención. En texto libre se declara **abstencion: true** cuando ninguna cita queda respaldada o cuando el LLM no responde en el tiempo límite; nunca se entrega una respuesta simulada. Las cerradas siempre llevan letra (regla de los organizadores): la justificación se escribe antes que la letra, una segunda llamada elige la letra que respalda ese razonamiento y, si no queda una válida, se toma la opción con más respaldo léxico en los pasajes. En el test hubo 5 abstenciones, todas en semiabiertas.

Juez descartado. Un juez (Gemma 4 E4B) revisaba

si el borrador respondía la sub tarea y si cada afirmación tenía soporte, con un segundo ciclo de búsqueda. Medido con el mismo código: sin juez, RAGAS 0,485 contra 0,469, cerradas 13/15 contra 12/15 (en una rechazó un borrador correcto y el segundo ciclo lo dañó) y 8,9 s contra 15,8 s por pregunta. Sin él, además, los pasajes dependen solo de la búsqueda determinista.

5. Resultados sobre las preguntas de muestra

Tabla 4: Puntaje de `scripts/evaluate.py --split sample`.

Componente	Puntos	Posibles
Exactitud en cerradas (13/15)	17,33	20
Calidad de citación	18,37	20
Abstención calibrada	9,07	10
Subtotal sin RAGAS	44,77	50
Corrección en texto libre (RAGAS 0,442)	13,26	30
Total automático	58,03	80

La Tabla 4 es la configuración de la entrega (la que generó `submissions.jsonl`); las cifras deterministas son iguales en la A40 y en la RTX 4090. RAGAS, con el juez oficial, dio **0,442**, por debajo de la referencia (0,451). Una versión anterior (v14) midió 0,470; la diferencia (0,028) está en el límite de la variación del juez entre corridas ($\pm 0,02-0,03$), así que no se puede atribuir con certeza a los cambios posteriores. Recorrido de la parte determinista: 35,99 en una versión temprana del agente, 42,90 con siglas y sin caché de prompts, y 44,77 con las fuentes de los pasajes en el fundamento. Sobre el test: 992 registros válidos contra el esquema y las 290 cerradas con letra.

Errores más frecuentes. Quedan 2 cerradas falladas y ninguna se resuelve sin sobreajustar: en la 128 el corpus no respalda la opción con “Fintech” en leasing, y en la 748 el art. 137 del CPACA (falsa motivación) no llega al top-10. Se corrigieron dos que antes fallaban: una pregunta que nombra la SIC por su sigla (ahora la expande y trae el art. 24 del CGP) y una cuantía en pesos (ahora entra el decreto del salario mínimo y una calculadora determinista convierte el monto). En texto libre, las respuestas con puntaje casi nulo son de contenido: búsqueda de otro tema, respuesta fuera del corpus o razonamiento del 8B con los pasajes correctos.

6. Limitaciones

1. **Preguntas abiertas.** Son casos que no nombran la norma: el recall cae a 0,500 / 0,500 contra $\approx 0,97$ / 0,90 en los otros formatos. Son solo 5 preguntas en la muestra, así que la cifra es poco precisa. La reescritura de la consulta con el LLM se probó y se descartó: inventaba normas y bajó el recall de documentos de 0,881 a 0,798.
2. **Dispersión jurisprudencial.** Las ventanas de sentencias son el 86 % de los chunks y muchas copian el

mismo párrafo. La lista de normas, el tope de 4 sentencias y el filtro de duplicados lo contienen, pero son reglas fijas: una pregunta que necesite más de 4 pasajes de jurisprudencia queda corta, y las sentencias de la Corte Suprema se tratan como normas y no siempre producen una cita reconocible (9 de 410).

3. **Ajuste sobre 50 preguntas.** Castigos, topes y umbrales se eligieron con la misma muestra con que se reportan; el desempeño en las 992 preguntas ciegas puede ser menor.
4. **Lo que no está en el corpus no se puede citar.** 117 documentos no están en la fuente oficial (90 de la Corte Suprema) y algunas providencias que cita el test no se consiguieron en fuente oficial.
5. **Determinismo del decoder.** Los pasajes son idénticos entre máquinas, pero el texto generado puede cambiar con el hardware aun con temperatura 0: algunas cerradas en el límite cambian de letra. Por eso la corrida del test y la verificación en vivo se hacen en la misma máquina.
6. **Pasajes gigantes.** En 5 de 50 preguntas un solo artículo con anexos supera el presupuesto y se recorta; el modelo puede no ver la parte pertinente.
7. **RAGAS limitado por el contenido.** Cambios de forma (largo, ejemplos de estilo, oraciones sustantivas, modo de razonamiento) no superaron la configuración final; lo que falta depende de la búsqueda, del corpus y del razonamiento del 8B.