

Informe técnico — Samu-Enjoyer

RAG agéntico de derecho colombiano con modelos abiertos pequeños

Santiago Gómez Camilo Murcia Angie Gutiérrez

Hackathon 2026 · Universidad de los Andes

1. Arquitectura del sistema

El sistema responde preguntas de derecho colombiano con un decoder abierto de 8B de parámetros y un corpus propio, bajo una regla: *toda norma citada debe figurar en los diez pasajes recuperados*. Tiene una parte fuera de línea y una en línea.

Fuera de línea (corpus e índice). Se descargaron 31.157 documentos objetivo de fuentes oficiales (Senado, Presidencia, relatorías de la Corte Constitucional, la Corte Suprema y el Consejo de Estado, DIAN, Función Pública, Cancillería y Colpensiones): **31.037 quedaron procesados (99,6 %)**, 24,86 GB de originales; las 117 fallas son documentos que la fuente oficial ya no entrega. Cada documento se convirtió a Markdown con metadatos (`tipo_norma`, `numero`, `anio`, `vigencia`); las capas de texto ilegibles se relevaron con OCR. La segmentación produjo **2.210.629 chunks**: 276.958 de normas (un artículo por chunk), 23.954 fichas de sentencias y 1.909.717 ventanas de sentencias.

En línea. El flujo es un `StateGraph` de LangGraph, sin memoria entre preguntas y sin ramas paralelas: `entrada` → `consulta_cerrada` | `reescribir_consulta` → `recuperar` → `escribir` → `validar_fuentes` ↔ `buscar_citas` → `juzgar` → `finalizar`. Las cerradas buscan con la pregunta más sus cuatro opciones, sin LLM; las semiabiertas y abiertas pasan por un reescritor de consulta. El escritor redacta solo con los diez pasajes, un validador determinista revisa las citas y un juez (otro modelo) puede pedir un segundo y último ciclo con nueva búsqueda. Ninguna llamada sale de la máquina: los modelos se sirven en `localhost` y el trazado externo está apagado.

2. Selección de encoder y decoder

La elección se hizo con un banco de pruebas sobre las 50 preguntas de muestra: 3 encoders × BM25 con y sin raíces × 2 rerankers y sin reranker, en el subcorpus de normas y fichas (300.912 chunks). La Tabla 1 resume los brazos comparables y la Tabla 2, la decisión.

Sin ajustes, `e5-large-instruct` recupera algo más de citas (0,911 contra 0,898), pero `Qwen3-Embedding-0.6B` trae más documentos de referencia y los ordena mejor, y con los ajustes de orden gana en las cuatro métricas. `Qwen3-Reranker-0.6B` empeora todas las métricas frente a no reordenar y es 4,5 veces más lento (1,14 s contra 0,25 s).

Configuración de inferencia. Cuantización de 4 bits

Tabla 1: Banco de pruebas, subcorpus de normas y fichas, $k = 10$, $n = 50$. R-c: recall de citas; R-d: recall de documentos; s: segundos del reranker por pregunta (servidor de referencia).

Brazo	R-c	R-d	MRR	nDCG	s
<i>Encoder (BM25 con raíces + bge-reranker-v2-m3, sin ajustes)</i>					
Qwen3-Embedding-0.6B	0,898	0,715	0,431	0,554	0,25
e5-large-instruct	0,911	0,667	0,390	0,509	0,26
bge-m3	0,874	0,679	0,405	0,522	0,26
<i>Reranker (Qwen3-Embedding-0.6B + BM25 con raíces)</i>					
bge-reranker-v2-m3	0,898	0,715	0,431	0,554	0,25
Qwen3-Reranker-0.6B	0,833	0,654	0,337	0,461	1,14
Sin reranker	0,841	0,707	0,436	0,572	—
<i>Con ajustes de orden (perfil completo)</i>					
Qwen3-Emb. + bge-rer.	0,935	0,837	0,448	0,601	0,25
e5-large + bge-rer.	0,898	0,752	0,399	0,537	0,26

(Q4_K_M), contexto de 32.768 tokens, temperatura 0, `top_k` = 1, semilla fija, sin modo de razonamiento y peticiones secuenciales. Los diez pasajes comparten un presupuesto de 85.000 caracteres: los que caben van completos y solo se recortan los gigantes; en la muestra, 45 de 50 preguntas entran sin recorte y el prompt más largo mide 25.318 tokens. La recuperación toma ≈ 1 s por pregunta en el servidor de referencia y 6,4 s en un portátil de consumo (RTX 3050 Ti de 4 GB, encoder en CPU y reranker en GPU), con los mismos pasajes y las mismas métricas: el sistema se reproduce en el hardware de la verificación en vivo sin degradar resultados.

3. Estrategia de recuperación

Segmentación. Un chunk por artículo, con su ruta jerárquica y un encabezado citable; los artículos largos se parten y se reúnen al entregar. Notas, preámbulos y anexos van aparte. Cada sentencia aporta una ficha (tesis y resuelve) y ventanas de ≈ 1.700 caracteres por sección. El identificador canónico es `<doc_id>/art_<N>`, por ejemplo `codigo_general_proceso/art_42`.

Búsqueda híbrida. Cinco listas entran a una fusión RRF ($k = 60$): las citas expresas de la pregunta (búsqueda exacta por identificador), BM25 (`bm25s`, raíces Snowball, sin quitar *stopwords*, identificadores normativos en un solo token; 100 candidatos), HNSW denso ($M = 32$, `efSearch` = 256; 100 candidatos) y una *lista de normas*: BM25 y HNSW sobre solo los 276.958 chunks de normas, 50 candidatos cada uno. Esta lista existe porque las sentencias son el 86 % del corpus y dejaban los códigos y la Constitución en las posiciones 100 a 900.

Reordenamiento y selección. El reranker puntúa

Tabla 2: Componentes elegidos.

Componente	Modelo	Motivo de la elección	Alternativas descartadas
Encoder	Qwen/Qwen3-Embedding-0.6B (dim. 1024), FAISS HNSW con cuantización escalar de 8 bits	Mejor recall de documentos y mejor orden del banco; 0,935 / 0,837 con ajustes. Cabe en un portátil de 4 GB (corre en CPU) con los mismos pasajes que en el servidor de referencia.	bge-m3 (0,874 / 0,679) y e5-large-instruct (0,911 / 0,667)
Decoder	Qwen/Qwen3-8B , GGUF Q4_K_M en llama.cpp	Abierto, dentro del límite de 8B; el mismo motor y el mismo archivo corren en el servidor de referencia y en el portátil de la verificación en vivo.	Modo de razonamiento de Qwen3: no es replicable en CPU (≈ 2 tokens/s)
Reranker	BAAI/bge-reranker-v2-m3 (fp16) sobre 150 candidatos	Sube el recall de citas de 0,841 a 0,898 en el banco; 0,66 s por pregunta en el corpus completo.	Qwen3-Reranker-0.6B: peor (0,833 / 0,654) y 4,5× más lento
Juez	Gemma 4 E4B en Ollama, servidor aparte	Un modelo abierto distinto del escritor: llama.cpp ignora el campo <code>model</code> , así que con la misma URL Qwen se juzgaba a sí mismo.	Qwen3-8B como juez de sus propios borradores

los 150 primeros de la fusión. Después se castiga por tipo (preámbulo 0,2; notas 0,15; ventana de sentencia 0,1; anexo 0,1) y por vigencia (**norma derogada 0,15**), se suma 0,1 a las normas de prioridad alta, y se limita a 4 sentencias y 3 pasajes por documento. Un filtro de casi duplicados salta el pasaje que no es artículo de norma y repite al menos el 70 % del texto de uno ya elegido (65 de 500 pasajes de la muestra repetían a otro). Salen **10 pasajes**; todo empate se resuelve por identificador, así que el resultado es determinista: el portátil (RTX 3050 Ti / CPU) devolvió los mismos 10 pasajes en el mismo orden que el servidor de referencia en 50 de 50 preguntas.

Tabla 3: Corpus completo (2.210.629 chunks), $k = 10$, $n = 50$.

Configuración	R-c	R-d	MRR	nDCG
Sin ajustes (base)	0,862	0,439	0,236	0,314
+ castigos, prioridad y topes	0,862	0,667	0,294	0,421
+ 150 al reranker, castigo ventanas	0,898	0,764	0,380	0,520
+ lista de normas (50 + 50)	0,919	0,785	0,416	0,552
+ sin casi duplicados (final)	0,919	0,809	0,419	0,561

Por formato (R-c / R-d, antes del filtro de duplicados)

Cerradas (15): 0,962 / 0,808

Semiabiertas (30): 0,965 / 0,819

Abiertas (5): 0,500 / 0,500

La Tabla 3 muestra el recorrido. El recall de documentos casi se duplica (0,439 a 0,809): es el techo de citas del agente, porque el validador solo acepta citas de documentos presentes en los diez pasajes. Se probaron y descartaron, con datos: una búsqueda por cada opción en las cerradas (recall de documentos 0,772), el seguimiento de las normas citadas por los primeros resultados (sin cambio), más candidatos sin más reranker, y topes más estrictos de sentencias.

4. Verificación de citas y abstención

El escritor cita con identificadores canónicos entre corchetes. La verificación es **determinista y sin LLM**: cada cita se convierte a `<doc_id>/art_<N>` y se busca entre los diez pasajes; la que no está se suprime del borrador (nodo `buscar_citas`). Agregar el pasaje de una cita ausente está implementado y apagado: la afirmación no se habría redactado con ese texto y los pasajes dejarían de depender solo de la búsqueda que se reproduce en la verificación en

vivo.

Al entregar, cada identificador se reescribe a la forma que reconoce el evaluador oficial con el nombre que trae el encabezado del pasaje (“artículo 42 del Código General del Proceso (Ley 1564 de 2012)”). Con los pasajes reales de las 50 preguntas, **401 de 410 citas quedan reconocidas y respaldadas**; las 9 restantes son sentencias de la Corte Suprema sin cita reconocible en su propio texto.

Abstención. Se declara `abstencion: true` cuando ninguna cita queda respaldada, cuando el juez indica que los pasajes no bastan, o cuando el LLM no responde en el tiempo límite; nunca se entrega una respuesta simulada. El juez revisa si el borrador responde la subtask y si cada afirmación tiene soporte. En las cerradas vota a ciegas con los mismos pasajes: si su letra difiere de la del escritor hay un segundo ciclo con nueva búsqueda y, si la diferencia persiste, queda la respuesta del escritor; una discrepancia nunca fuerza la abstención.

5. Resultados sobre las preguntas de muestra

Tabla 4: Puntaje de `scripts/evaluate.py --split sample`.

Componente	Puntos	Posibles
Exactitud en cerradas	—	20
Calidad de citación	—	20
Abstención calibrada	—	10
Total automático sin RAGAS	—	50

La Tabla 4 se llena con la corrida final del evaluador oficial. Los datos disponibles son de pruebas anteriores. En una prueba temprana del agente, el escritor acertó **11 de 15 cerradas**. Antes, con un corpus reducido de 291 documentos, el mismo Qwen3-8B pasó de 9 a 12 cerradas correctas al darle pasajes, y las normas citadas que no existen bajaron de 21 de 80 a 0 de 91.

Errores más frecuentes. De las 4 cerradas falladas, ninguna es de razonamiento: dos piden un dato que no está en ningún pasaje (el valor del salario mínimo para una cuantía; una opción con el término “Fintech”), una es de recuperación (no llega el CPACA) y una tiene la clave errada (cita una “Ley 1564 de 2002” que no existe).

Un error de formato sí se corrigió: con la letra antes de la justificación el modelo elegía antes de razonar; ahora el prompt pide primero la justificación.

6. Limitaciones

1. **Preguntas abiertas.** Son casos que no nombran la norma: el recall cae a 0,500 / 0,500 contra $\approx 0,96$ / 0,81 en los otros formatos. Son solo 5 preguntas en la muestra, así que la cifra es poco precisa, y el reescritor de consultas que debe cubrir este caso no está medido.
2. **Dispersión jurisprudencial.** Las ventanas de sentencias son el 86 % de los chunks y muchas copian el mismo párrafo. La lista de normas, el tope de 4 sentencias y el filtro de duplicados lo contienen, pero son reglas fijas: una pregunta que necesite más de 4 pasajes de jurisprudencia queda corta, y las sentencias de la Corte Suprema se tratan como normas y no siempre producen una cita reconocible (9 de 410).
3. **Ajuste sobre 50 preguntas.** Castigos, topes y umbrales se eligieron con la misma muestra con que se reportan; el desempeño en las 992 preguntas ciegas puede ser menor.
4. **Datos que el corpus no trae en forma útil.** Valores anuales (salario mínimo, UVT) no siempre llegan a los diez pasajes, y 117 documentos no se pudieron descargar de la fuente oficial.
5. **Determinismo del decoder.** Los pasajes son idénticos entre máquinas, pero el texto generado en GPU (nodo de cómputo) y en CPU (portátil) puede diferir aun con temperatura 0; falta la comparación de normas citadas entre ambas.
6. **Pasajes gigantes.** En 5 de 50 preguntas un solo artículo con anexos supera el contexto y se recorta.
7. **Sin medir.** El voto del juez en las cerradas y el juez Gemma no tienen todavía resultados sobre la muestra.